Date: 8 Aug 2026 (5th class)

Language Model using N-Grams

- Syntax - (subject, object, verb), Exp: আমি ভাত খাই I eat rice (sub obj verb sub verb object)
- Semantics - (অর্থ/order sentence ঠিক থাকা)
- Pragmatics - (প্রাসঙ্গিকতা থাকে কিনা)

P (আমি ভাত খাই) = ? 0.93

P (চাঁদ আকাশে উড়ে) = ? 0.0029

Sentence = $w_1\ w_2\ w_3 \ldots\ w_n$

Sentence = আমি ভাত খাই
(w_1 w_2 w_3)

$P(\text{Sentence}) = P(w_1\ w_2\ w_3 \ldots\ w_n)$

$= P(w_1) * P(w_2|w_1) * P(w_3|w_1 w_2) * \ldots * P(w_n|w_1 w_2 w_3 \ldots w_{n-1})$

P (আমি ভাত খাই) = P (আমি) * P(ভাত|আমি) * P (খাই|আমি ভাত)

= Large value * Relatively smaller value * Smallest value

↳ Data Sparcity Problem

↓

Way of Resolve N-gram language model

N = 1, Unigram language model (এক word)

N = 2, Bigram language model (পাশাপাশি দুই word)

N = 3, Trigram language model (পাশাপাশি তিন word)

Unigram language model

ঘর আকাশে উড়ে

= P (ঘর) * P (আকাশে | ঘর) * P (উড়ে | আকাশে) =
= P (ঘর) * P (আকাশে) * P (উড়ে)
= overall Large value ← যদি separate ভাবে Probability বের করা হয় তাহলে সেই Sentence টি valid যদিও বাস্তবে এটি অসম্ভব।

Bigram Language model

P (ঘর | আকাশে উড়ে)

= ~~P (ঘর) * P~~
= P (ঘর | start) * P (আকাশে | ঘর) * P উড়ে | আকাশে)
= many * small value * small
= Average কিছু value পাওয়া যাবে। তার মধ্যে এটি valid Sentence. এখানে দুইটি করে word নেয়া হয়েছে।

Trigram Language Model

P (ঘর আকাশে উড়ে)
= P (ঘর | start start) * P (আকাশে | start ঘর) * P (উড়ে | ঘর আকাশে)
= many * small * few
= valle (smallest value) এখানে তিনটি করে word নেয়া হয়েছে

পরীক্ষায় কিভাবে আসবে?

সমস্যা-১ আমি ভাত খাই
সে ভাত খায়
তুমি ভাত খাও
আমরা ভাত খাই

Text Corpus (মোট সর্বোমোট ২২টি word)

a) Now find unigram probability of
আমি, ভাত, খাই (আলাদা আলাদা word)

b) find unigram probability of
আমি ভাই খাই (পুরো বাক্য Sentence)

সমাধান :

a) P (আমি) = ?
P (ভাত) = ?
P (খাই) = ?

Formulla $P(w) = \frac{\text{Count}(w)}{\text{Count(all words)}}$

$\therefore P(\text{আমি}) = \frac{\text{Count (আমি)}}{\text{Count(all words)}}$

$= \frac{1}{12} = 0.083$

$\therefore P(\text{ভাত}) = \frac{\text{Count ভাত}}{\text{Count (all words)}}$

$= \frac{4}{12}$

$= \frac{1}{3} = 0.333$

$$\therefore P(\text{খাই}) = \frac{\text{count খাই}}{\text{count(All words)}}$$

$$= \frac{2}{12}$$

$$= \frac{1}{6}$$

$$= 0.167$$

b) P(আমি ভাত খাই)

$$= P(\text{আমি}) * P(\text{ভাত}) * P(\text{খাই})$$

$$= 0.083 * 0.333 * 0.167$$

$$= 0.0046$$

(Threshold Assume 0.5)

সমাধান-2

আমি ভাত খাই
সে ভাত খায়
তুমি ভাত খাও
আমরা ভাত খাই
তাহারা ভাত খায়

Text Corpus

i) find P(খাই|ভাত)

ii) find P (আমরা ভাত খাই) using Bigram model

সমাধান

$$P(\text{খাই}|\text{ভাত}) = \frac{\text{count(ভাত খাই)}}{\text{count ভাত}} = \frac{2}{5}$$

ii) P(আমরা ভাত খাই) = P(আমরা|start) * P(ভাত|আমরা) * P(খাই|ভাত)

$$= \frac{\text{Count (start আমরা)}}{\text{Count (start)}} * \frac{\text{Count (আমরা ভাত)}}{\text{Count (আমরা)}} * \frac{\text{Count (ভাত খাই)}}{\text{Count (ভাত)}}$$

$$= \frac{1}{5} * \frac{1}{1} * \frac{2}{5}$$

$$= \frac{2}{25}$$

সমস্যা-৩

আমাদের স্কুলে যাওয়া উচিত
আমাদের স্কুলে যাওয়া উচিত হয় নাই
তাহাদের স্কুলে যাওয়া ঠিক নই
করিমের স্কুলে যাওয়া উচিত
আমাদের স্কুলে যাওয়ার সিদ্ধান্ত সঠিক ছিল

] Text Corpus

i) Find P(উচিত | স্কুলে যাওয়া)

ii) find P(করিমের স্কুলে যাওয়া উচিত)
using trigram Language model

সমাধান:

i) $P(\text{উচিত} \mid \text{স্কুলে যাওয়া}) = \frac{\text{Count (স্কুলে যাওয়া উচিত)}}{\text{Count (স্কুলে যাওয়া)}} = \frac{3}{4}$

ii) P(করিমের স্কুলে যাওয়া উচিত) = ?

P(করিমের | start start) * P(স্কুলে | start করিমের) * P(যাওয়া | করিমের স্কুলে)
* P(উচিত | স্কুলে যাওয়া)

$$= \frac{\text{Count(Start Start বরাবর)}}{\text{Count(Start Start)}} * \frac{\text{Count(Start করণের মূলে)}}{\text{Count(Start-করণ)}} *$$

$$\frac{\text{Count(করণের মূলে লাগবে)}}{\text{Count(করণের মূলে)}} *$$

$$\frac{\text{Count(মূলে লাগবে উচিত)}}{\text{Count(মূলে লাগবে)}}$$

$$= \frac{\text{Count (START করণের)}}{\text{Count (Start)}} * \frac{\text{Count Start (করণের মূলে)}}{\text{Count(Start করণের)}} *$$

$$\frac{\text{Count(করণের মূলে লাগবে)}}{\text{Count(করণের মূলে)}} * \frac{\text{Count(মূলে লাগবে উচিত)}}{\text{Count(মূলে লাগবে)}}$$

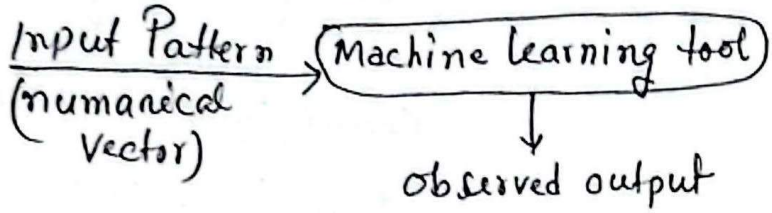
$$= \frac{1}{5} * \frac{1}{1} * \frac{1}{1} * \frac{3}{4}$$

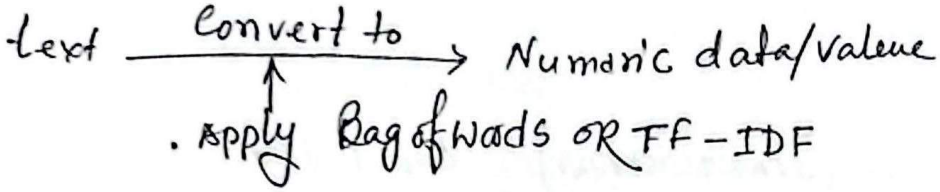
সেন্স টু Sentence

$$= \frac{3}{20}$$

Feature Extraction in NLP

- Bag of Words
- TF – IDF (Term Frequency – Inverse documents frequency)





Example: Step-1 : Data Collection

It was the best of times
it was the worst of times
it was the age of wisdom
it was the age of foolishness

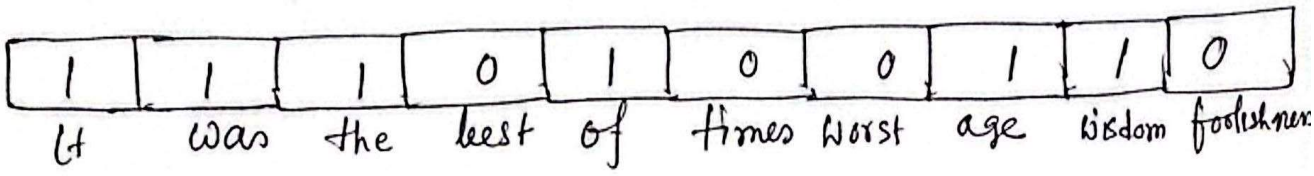
Step 2 : Make a list of all words

IT, it, was, the, best, of, time, worst, age, wisdom, foolishness

Step 3 : Identify Unique words (Ignore Capital/Small, Synonym)

it, was, the, best, of, times, worst, age, wisdom, foolishness

STEP: 4 Construct feature vector



It was the age of wisdom